

# 面向机械振动信号的自主信号处理大语言模型智能体

李 奇<sup>1,2</sup>, 张昕然<sup>1</sup>, 胡文扬<sup>1</sup>, 张飞斌<sup>1</sup>, 秦朝烨<sup>1</sup>, 褚福磊<sup>1</sup>

(1. 清华大学机械工程系, 北京 100084; 2. 耶鲁大学统计与数据科学系, 纽黑文 06511)

**摘要:** 振动信号分析是机械设备状态监测与故障诊断的核心手段, 但其面临着一个核心困境, 即传统专家系统流程固化, 而端到端的深度模型虽具自适应学习能力, 却存在“黑箱”与可复现性不足等问题。本文提出一种自主信号处理的神经符号多智能体框架: 以大语言模型(LLM)作为决策中枢, 协同一个由可解释的、符号化的信号处理算子构成的工具箱, 实现自主的振动信号分析与诊断。框架采用规划-执行-审查的多智能体架构, 迭代优化信号处理决策链。同时为确保 LLM 规划的逻辑自洽, 避免出现算子的错误调用, 所有算子都依据其维度变化与语义变换特性被形式化规约。具体地, 将算子划分为升维、同维、降维、多信号四类, 并给出供大模型理解的语义信息加以约束。轴承故障诊断数据集上的验证表明: 本框架能够自主生成具有清晰物理含义的信号处理决策链, 成功复现了“包络谱-峭度”等专家级可解释的诊断算法。在清华大学轴承数据集的单域测试中, Gemini 2.5 Pro 版本达到 97.8% 的准确率; 在渥太华大学变转速数据集的跨域测试中, 仅用“加速”和“减速”工况训练, 在未见过的工况上实现了 99.3% 的准确率, 证明了框架的泛化能力。该研究为构建可信、可复现且可扩展的新一代智能诊断系统提供了一种具有潜力的范式。

**关键词:** 大语言模型; 神经符号; 可信人工智能; 多智能体; 决策链; 故障诊断

**中图分类号:** TH165+.3 **文献标志码:** A **DOI:** 10.16385/j.cnki.issn.1004-4523.202508034

## An LLM-based agent for autonomous signal processing of mechanical vibration signals

LI Qi<sup>1,2</sup>, ZHANG Xinran<sup>1</sup>, HU Wenyang<sup>1</sup>, ZHANG Feibin<sup>1</sup>, QIN Zhaoye<sup>1</sup>, CHU Fulei<sup>1</sup>

(1. Department of Mechanical Engineering, Tsinghua University, Beijing 100084, China;

2. Department of Statistics and Data Science, Yale University, New Haven 06511, USA)

**Abstract:** Vibration signal analysis is a cornerstone of machine condition monitoring and fault diagnosis, yet it faces a central dilemma. Traditional expert systems have rigid workflows, while end-to-end deep models, despite their adaptive learning abilities, suffer from being ‘black boxes’ with insufficient reproducibility. This paper introduces a neuro-symbolic multi-agent framework for autonomous signal processing. The framework utilizes a large language model (LLM) as a central decision-maker, coordinating a toolbox of interpretable, symbolic signal processing operators to enable autonomous vibration signal analysis and diagnosis. The framework adopts a Plan-Execute-Review multi-agent architecture to iteratively optimize the signal processing decision chain. To ensure the logical consistency of the planning and prevent incorrect operator calls, all operators are formally regulated based on their dimensional and semantic transformation properties. Specifically, they are constrained by semantic information for the LLM to comprehend. Validation on bearing fault diagnosis datasets shows that this framework can autonomously generate signal processing decision chains with clear physical meaning and has successfully reproduced expert-level, interpretable diagnostic algorithms such as ‘envelope spectrum-kurtosis’. In single-domain tests on the Tsinghua University bearing dataset, the Gemini-2.5-pro version reached an accuracy of 97.8%. In cross-domain tests on the University of Ottawa variable-speed dataset, the framework, trained solely on ‘acceleration’ and ‘deceleration’ conditions, achieved 99.3% accuracy on unseen conditions, proving its generalization ability. This research provides a promising new paradigm for building trustworthy, reproducible, and scalable next-generation intelligent diagnostic systems.

**Keywords:** large language model; neuro-symbolic; trustworthy AI; multi-agent; decision chain; fault diagnosis

振动信号分析是机械设备状态监测与故障诊断的核心技术之一。轴承、齿轮等旋转部件一旦产生裂纹、磨损或失衡, 其动态行为会首先体现在振动信号模式的变化上, 因此精准捕捉并解释信号中的

异常是避免灾难性故障的关键手段<sup>[1]</sup>。针对这一目标, 研究者提出了多种基于时频分析与统计度量的方法。例如, 甄冬等<sup>[2]</sup>将改进的集成经验模态分解与调制信号双谱结合, 用分解得到的本征模态函数

提取滚动轴承早期故障特征。文献 [3-4] 则围绕旋转机械中的重复瞬态分量构建了基于基尼指数等稀疏测度的系列算法。YAN 等<sup>[5]</sup>系统回顾了小波变换的多分辨率分析优势,指出其在旋转机械故障诊断中的持续创新潜力。针对旋转机械振动分析,形成了预处理、时频变换、特征提取、模式识别的经典流程。该流程通过一系列具有明确物理意义的“算子(operator)”组合,将原始振动信号转化为可供决策的特征。表 1 总结了主要阶段、典型算子及其目的。

表 1 振动信号处理典型算子及其目的  
Tab. 1 Typical operators in vibration signal processing and its purposes

| 阶段    | 典型算子            | 主要目的                           |
|-------|-----------------|--------------------------------|
| 预处理   | 滤波、归一化等         | 提升信噪比, 去除无关干扰等                 |
| 时/频变换 | 傅里叶变换、小波变换等     | 将时域信号转换到频域或时频域, 揭示周期冲击等故障特征频率等 |
| 特征提取  | 均方根、稀疏测度、复杂性测度等 | 量化并用于模式识别等                     |

尽管这套由专家手工编排的分析方法经过了长期实践检验,具备良好的可解释性,但其开发与维护过程高度依赖专家经验。研究者需要针对特定设备与工况,人工选择滤波器、变换域及统计量并反复调参。这种为特定场景设计的“特解”不仅费时费力,其固定的决策链也难以适应多变的工况、新型故障模式或大规模非平稳数据,导致诊断性能显著下降。为突破“人工设计”的瓶颈,以深度学习为代表的神经主义范式为端到端特征学习带来了革命。然而,这类数据驱动的深度模型将诊断过程封装为“黑箱”,导致模型可复现性不足,泛化到分布外数据的能力有限<sup>[6]</sup>,且其决策过程难以与物理先验知识显式融合<sup>[7-8]</sup>。因此,在要求高安全与高可靠性的工业场景中,可解释性与可信度不足仍是深度模型落地的主要障碍。“可解释但固化”的传统方法与“自适应但黑箱”的深度模型之间的核心困境,凸显了构建新一代智能诊断系统的迫切需求。

近年来,神经符号人工智能(neuro-symbolic AI)的兴起为平衡“可解释”与“自适应”提供了思路,LI 等<sup>[9-11]</sup>受到神经符号主义的启发,通过构建信号处理符号算子库,利用神经网络进行自学习地调度组装,执行并优化不同可解释算子从而搭建端到端的可解释网络。同时,以语言符号为载体训练的大型语言模型(LLM)在推理与规划方面的突破展示了跨领域的通用智能潜力。传统 LLM 在故障诊断方面的应用主要集中于两个方面:一是处理文本类数据(如维修日志),无法分析原始振动信号,例如文献 [12-13]

知识图谱与维保文档的构建,普遍以维修语料、工单文本等为输入,借助 LLM 做实体关系抽取与文档生成,面向机器人等装备进行运维;二是将 LLM 作为端到端的“黑箱”分类器,例如 FD-LLM 将频谱或统计特征序列转成可被 LLM 读入的文本/表格式表示,再进行分类<sup>[14]</sup>,这继承了深度学习模型可解释性不足、泛化能力有限的特点<sup>[15]</sup>。

LLM 凭借大规模训练具备强理解、生成与推理能力,随规模与上下文的扩展,涌现出长期记忆、链式推理与工具使用的能力,具备充当主动决策核心的潜力。ALUR 等<sup>[16]</sup>指出开发准确、性能优良,且安全和可信的 AI 决策系统,可以结合神经网络和符号推理的优势,以提高 AI 系统的可解释性和可验证性,开发可靠、可预测且符合伦理标准的可信 AI 智能体(trustworthy AI agents)。微软的 HuggingGPT 验证了 LLM 作为智能体驱动任务规划与工具调用的可行性<sup>[17]</sup>。HUANG 等<sup>[18]</sup>则进一步验证了 LLM 通过“自我验证”策略已达到国际数学奥赛金牌水平。

尽管单个 LLM 智能体能力强大,但在应对如信号处理般复杂的、多阶段的工程任务时,往往会受到 LLM 上下文长度的限制而导致规划僵化或决策遗漏。而多智能体系统(multi-agent system, MAS)可以让多个智能体通过协作或竞争共同完成任务,通过维护自身的上下文,智能体可以利用自然语言或结构化的消息进行对话,从而动态地生成、评估和修订计划,极大地降低了系统耦合度,提升了整体方案的鲁棒性与全局性。

如图 1 所示,一个典型的多智能体<sup>[19]</sup>工作流可被抽象为“感知-思考-行动”的循环:通过将环境状态、任务目标和可用工具等信息编码为自然语言提示,LLM 能够自主进行任务分解、步骤规划,并最终输出文本决策。相比于规则固化的传统专家系统,




图 1 大语言模型驱动的智能体工作流

Fig. 1 Large language model-driven agent workflows

LLM 智能体无需人工枚举所有规则, 展现了策略生成能力和泛化性。

在人工智能飞速演进的背景下, 本文旨在破解一个核心难题: 能否借助 LLM 的强大推理与规划能力, 联合一个可解释的符号化信号处理算子库, 在无需后训练的情况下, 构建一套可自主、可解释、可验证、可复现的振动信号分析智能体? 具体而言, 为解决该难题, 需要完成若干挑战:

(1) 传统振动分析依赖专家, 难以自动化; 而 LLM 虽具备通用推理能力, 却无法直接进行精确的数值计算, 存在“幻觉”风险。

(2) 若直接让 LLM 调用外部工具(如信号处理库)时, 其“幻觉”可能导致生成错误的函数名或参数, 引发执行失败或灾难性后果。

(3) 在复杂的信号处理任务中, 单一智能体容易陷入局部最优或规划僵化, 难以生成全局最优的诊断策略。

为应对此挑战, 本文提出一种由 LLM 驱动的神神经符号多智能体框架。其核心思路是借鉴人类专家团队的协作模式: 以 LLM 充当决策中枢(“大脑”), 并引入一个由“规划者”“执行者”和“审查者”构成的多智能体协作架构。“规划者”负责提出宏观策略, “执行者”调用算子库进行精确计算, 而“审查者”则对结果进行批判性评估与反馈。在这种迭代循环中, 系统动态地生成并优化一个由具体信号处理算子构成的有向无环图决策链(DAG)。为确保 LLM 规划的逻辑严谨性并杜绝“幻觉”, 为所有算子建立了形式化的神经符号规约, 保证整个决策链的构建过程可由 LLM 自主组合和安全验证。试验结果表明, 该框架能生成具有清晰物理含义的决策链, 在单域与跨域诊断任务中均实现了诊断流程的可追溯与可信化。

为清晰定位本框架的独特性, 将自主信号处理的神神经符号多智能体框架与当前主流技术范式(专家系统、端到端神经网络、LLM)在关键能力维度上进行系统性对比, 结果如表 2 所示。本框架并非是对现有技术的简单替代, 而是通过一种方式, 将多种 AI 范式的优点进行深度融合与协同。

(1) 对比传统专家系统

本框架具备专家系统的可解释性, 但通过 LLM 的自主学习和规划能力, 从根本上克服了专家系统规则固化、难以扩展的瓶颈, 实现了从“静态知识库”到“动态决策大脑”的飞跃。

(2) 对比端到端神经网络

本框架在保留神经网络自适应学习能力的同时, 通过符号化算子库和可追溯的 DAG, 有效缓解了其“黑箱”问题。更重要的是, 面对新任务或跨域

挑战时, 本框架的优势在于从“模型训练”范式转变为“逻辑调度”范式。它通过 LLM 的宏观规划对原子算子进行灵活地逻辑重组, 而非依赖海量数据进行模型重训练, 因此具备更强的动态适应性和更短的开发部署周期。

(3) 对比通用大语言模型

本文核心工作是为 LLM 赋予了处理机械信号领域问题的能力。通过形式化的神经符号算子库, 将其 LLM 的通用推理能力“锚定”在具体的振动信号处理领域, 有效解决了 LLM 因缺乏领域知识而产生的“幻觉”, 以及无法安全执行精确计算的根本问题, 最终实现了其在工业场景下的安全、可靠应用。

表 2 相关工作对比

Tab. 2 Comparison of related work

| 对比维度 | 自主规划 | 可解释性 | 动态适应 | 领域知识 | 调用领域工具 |
|------|------|------|------|------|--------|
| 本工作  | √√   | √√   | √√   | √√   | √√     |
| 专家系统 | ×    | √√   | ×    | √√   | /      |
| 神经网络 | √    | ~    | √    | ×    | /      |
| LLM  | √    | ~    | √    | ×    | ×      |

注: “√√”表示具备该能力, “√”表示基本具备该能力, 但存在一定局限, “~”表示仅在特定条件下或间接方式下有所体现, “×”表示通常不具备该能力, “/”表示不适用。

本文针对传统专家系统规则固化与深度学习“黑箱”难解释的根本矛盾, 提出面向机械振动信号的神神经符号多智能体框架。它并非单一技术路线的延伸, 而是通过将 LLM 的宏观智能规划与符号化工具的微观精确执行相结合, 借助多智能体协作与动态决策图可视化分析过程的涌现与演化, 最终实现信号处理决策链的自主生成、动态优化与全程可解释。代码及补充内容可见主页: [https://github.com/PHMbench/PHMGA/tree/NVTA\\_2025\\_Version](https://github.com/PHMbench/PHMGA/tree/NVTA_2025_Version)。

## 1 构建的自主信号处理的神神经符号多智能体框架

图 2 直观地展示了本文提出的自主信号处理多智能体架构。该架构的核心目标是通过多智能体协作, 将传统上依赖专家经验的信号处理流程设计过程完全自动化。整个工作流以动态构建和执行一个信号处理决策链(在本文中表现为有向无环图, DAG)为中心, 并围绕两大阶段展开:

(1) 决策链构建

本框架的核心创新在于引入了一个由“规划者”“执行者”和“审查者”构成的多智能体闭环系统。在此阶段, 系统接收原始振动信号、用户指令和算



子库等初始信息,通过“规划-执行-审查”的迭代循环,自适应地生成并优化用于特征工程的决策链,直至满足审查者的终止条件。决策链的每个节点都包含算子以及父节点的信息。

(2)下游训练分析

当最优决策链构建完成后,系统进入分析与应用阶段。后续的一系列智能体(如决策链探针、数据规整器、机器学习器等)将依次启动,利用该决策链提取的特征,进行定量分析(如特征有效性评估)、机器学习模型训练与验证,并最终整合所有过程信息,自动生成一份详尽的诊断报告。




图 2 自主信号处理多智能体架构

Fig. 2 Multi-agent architecture for autonomous signal processing

1.1 问题定义: 信号处理决策链的优化

面向真实的工业诊断场景,本研究的核心问题可被形式化地定义为:如何驱动智能体系统,令其在给定的算子库中,自主地调用算子、构建并优化用

于设备故障诊断的信号处理决策链?

为此,首先定义以下基本元素:

(1) 任务指令  $I$ : 用户发出的高层次诊断目标,例如“诊断轴承 A 的故障”。

(2) 算子库  $\Phi$ : 一个包含了若干个原子信号处理算子的库。

(3) 信号数据集  $S$ , 将其划分为训练验证集  $S_{\text{train}}$  和测试集  $S_{\text{test}}$ 。

(4) 信号处理决策链  $D$ 。将决策链定义为一个由算子库  $\Phi$  中元素构成的 DAG。该 DAG 的拓扑结构  $D_{\text{topo}}$  与其内部每个算子的参数配置  $\theta$  均为待求解的变量。

基于上述定义,整个自主诊断过程可被分解为离线训练验证与在线测试两个阶段。

1.1.1 离线训练验证: 最优决策链生成

训练阶段的根本任务是学习并构建最优的决策链  $D^*$ 。在此阶段,多智能体系统以给定的训练数据  $S_{\text{train}}$  和任务指令  $I$  为输入,在所有可行决策链构成的解空间  $\mathcal{D}$  中进行学习。该学习过程旨在最大化预定义的综合效用函数  $U$  来识别最优的决策链结构  $D^*$  及其对应的参数配置  $\theta$ :

$$(D^*, \theta^*) = \arg \max_{D \in \mathcal{D}, \theta \in \Theta} U(D(\theta), S_{\text{train}}, I) \tag{1}$$

为简化问题并聚焦于核心的自主决策链构建能力,后续试验中不考虑计算成本,只关注诊断的性能指标。

1.1.2 在线部署测试: 泛化能力的评估与验证

为检验所生成决策链  $D^*$  的泛化能力,设计了独立的测试阶段。此阶段的核心在于评估该决策链在训练过程中未曾接触过的新数据  $S_{\text{test}}$  上的表现。该评估流程将固化的决策链  $D^*$  和未见的测试数据集  $S_{\text{test}}$  作为输入,进行前向推理,并输出两项关键结果:量化性能得分和一份详尽的,包含决策链拓扑、关键中间结果和最终结论的解释性报告。

1.2 信号处理算子的神经符号规约

为了使 LLM 对信号处理流程的自主规划,并自主构建有效的决策链,核心挑战在于杜绝 LLM 调用工具的“幻觉”,以及链接 LLM 强大的符号推理能力与精确的数值计算过程,需要构建一个包含经典、可解释算子的工具库  $\Phi$ , 其中的算子均是在机械故障诊断领域经过长期验证、具有明确物理意义的工具,覆盖了预处理、时频变换和特征提取等关键环节。进一步,针对算子库中的所有算子,提出一套神经符号规约 (neuro-symbolic specification), 通过规约, LLM 可以理解各类算子的语义信息从而正确调用算子工具, 这为智能体自主构建分析流程提供基础。 本文将每个信号处理步骤抽象为一个算子  $\phi$  及其参

数  $\theta$ , 它接收一个或多个信号张量  $\mathbf{X}$  作为输入, 并输出一个新的张量:

$$\mathbf{Y} = \Phi(\mathbf{X}; \theta), \mathbf{X} \in \mathbb{C}^{B \times D_1 \times D_2 \times \dots \times D_m \times C} \quad (2)$$

本文约定一批标准的多通道振动信号被表示为一个多维张量,  $B$  为样本数,  $C$  为通道数,  $D_m$  为其余的维度。除了维度的变化, 算子还会引起数据语义的变化。例如, 一个轴的语义可以从“时间域”转变为“频率域”。因此, 一个完整的算子规约不仅要定义其输入/输出的维度映射, 还需声明其语义变换。基于维度变换的特性, 将算子库中的原子操作归纳为以下 4 种基本类型: 升维、降维、同维以及多信号算子。升维算子旨在将输入张量扩展至更高维度的空间, 例如短时傅里叶变换算子。降维算子通过沿一个或多个轴进行信息聚合, 将输入张量压缩为更紧凑的低维表示, 通常用于特征提取, 例如平均算子。同维算子在不改变输入张量形状的前提下, 对其数值或语义进行变换例如傅里叶变换算子。多信号算子接收两个或以上独立的信号张量, 并输出一个描述它们之间相互关系的新张量, 例如相干谱算子。

在缺乏明确的安全规约时, LLM 智能体在信号处理任务中常出现两类失效: 其一为参数“幻觉”, 即臆造采样率、滤波阶次、带宽等超出物理/算法约束的超参数, 导致结果不稳定且难以复现; 其二为逻辑错配, 表现为规划与执行脱节、前后假设不一致、工具调用次序错误, 造成处理链路断裂。于多智能体协作情境中, 这些偏差会级联放大并形成“错误共识”, 引发无效甚至高风险操作(如无限重试与资源过耗)。其有效性见附录 A 中的失败案例与消融试验。本研究所用到的完整原子算子库及其详细规约可见前文提及的项目主页。

### 1.3 多智能体角色定义与协作机制

之所以采用多智能体而非单一智能体, 是因为此类任务不仅要求系统具备宏观的策略规划能力, 还需要确保规划能被精确、安全地转化为数值计算, 系统需要具备自我批判和迭代优化的能力, 在巨大的解空间中探索出高质量的方案。因此, 本节所阐述的协作机制, 旨在为解决本文所面临的核心挑战提供一个鲁棒且高效的解决方案。将整个系统的演化过程形式化地描述为一个状态转移系统。系统的全局状态  $S$  可被定义为一个元组:

$$S = (I, D, P, H, M, R) \quad (3)$$

式中,  $I$  为任务指令;  $D$  为信号处理决策链 DAG;  $P$  为待执行的计划;  $H$  为审查历史;  $M$  为最终的机器学习模型与结果;  $R$  为分析报告。每个智能体的功能可以被视为一个状态转移函数, 驱动系统从当前状态  $S_t$  演进至下一状态  $S_{t+1}$ 。

#### 1.3.1 规划智能体

规划智能体  $A_p$  是系统的认知核心, 负责宏观层面的任务分解与策略生成。它接收用户定义的任务指令  $I$  (例如, 诊断特定设备的故障类型), 并分析当前信号处理流程  $D_t$  的拓扑结构与语义。同时, 为了实现迭代优化并避免重复无效的探索, 该智能体会参考历史审查智能体生成的反馈信息  $H_t$ 。基于上述输入, 解析到智能体提示词模板中, 模板包括如下信息:

- (1) 身份定义;
- (2) 信号处理任务策略;
- (3) 算子库规约;
- (4) 输出格式与例子;
- (5) 参数占位符;
- (6) DAG 最小深度  $d$ 。

结合任务指令  $I$  和上述提示词, 规划智能体可生成一个具体、有序的原子操作序列, 即执行计划  $P_t$ , 用以指导下一阶段的计算。其状态转移功能可表示为:

$$P_t = A_p(I, D_t, H_t) \quad (4)$$

#### 1.3.2 执行智能体

执行智能体  $A_e$  是系统的程序化实现层, 负责将规划智能体制定的抽象计划  $P_t$  转化为具体的数值计算以及 DAG 的搭建。该智能体通过调用一个预定义的、经过验证的工业级算子库  $\Phi$ , 在信号数据上执行具体操作(如傅里叶变换、小波包分解、统计特征计算等)。每次执行的结果都会以新节点或新连接的形式更新到信号处理图  $D_t$  中, 从而生成新的图状态  $D_{t+1}$ 。这种设计将符号层面的规划与数值层面的计算进行了解耦, 确保了 LLM 在决策过程中的可靠性与计算过程的精确性。其状态转移功能可表示为:

$$D_{t+1} = A_e(D_t, P_t) \quad (5)$$

#### 1.3.3 审查智能体

审查智能体  $A_h$  扮演了元认知评估的角色, 是实现系统自我完善和鲁棒性提升的关键。在每一轮执行智能体完成操作后, 审查智能体会对更新后的图  $D_{t+1}$  进行批判性评估。评估的维度不仅限于执行的成功与否, 更侧重于策略的有效性, 例如特征集的冗余度、处理流程的逻辑连贯性以及当前进展与最终目标  $I$  的对齐程度。评估后, 它会生成一条结构化的反馈意见, 并将其追加到审查历史  $H$  中, 判断是否需要进一步优化  $D$ 。这个“规划-执行-审查”的反馈循环是本框架的核心机制之一。其状态转移功能可表示为:

$$H_{t+1} = A_h(I, D_{t+1}) + H_t \quad (6)$$

#### 1.3.4 下游分析智能体决策链探针智能体

当信号处理决策链  $D$  的构建阶段终止后, 决策链探针智能体负责对决策链  $D$  节点上存储的特征集

合进行效能的量化评估。它通过计算每个特征在不同工况(如正常与故障)下的分布差异或相似性度量 $Q$ ,探查其对诊断任务的贡献度。此过程为后续的机器学习建模提供了关键的先验知识,并对特征进行了一次筛选与解释。该智能体的输出是对决策链 $D$ 中叶子节点的属性进行标注,生成带有相似度量化评估的结果。

### 1.3.5 数据规整器与浅层机器学习智能体

数据规整器对提取出的特征进行标准化和规整。为了验证提取决策链的效果,本文采取的机器学习模型为支持向量机<sup>[20]</sup>。浅层机器学习智能体接收决策链 $D$ 各个节点的特征集,对决策链 $D$ 进行综合评估,并采用 $k$ 折交叉验证的方法,集成最优的模型,进行初步的模式识别或分类,得出一个初步的诊断结果 $M$ 。

### 1.3.6 研究报告智能体

整合上述所有智能体的分析结果、决策过程以及最终的诊断结论 $M$ ,按需调用外部知识库进行补充,研究报告智能体 $A_r$ 自动生成一份结构化的、人类可读的分析报告 $R$ :

$$R = A_r(I, D, H, Q, M) \quad (7)$$

综上,多智能体的伪代码如下。

#### 算法1: 神经符号多智能体主循环伪代码

**输入:** 任务指令 $I$ , 算子库 $\Phi$ , 最小深度 $d$ (默认为4), 初始计划 $P$ , 审查历史 $H$

**输出:** 有向无环图决策链 $D$ , 分类器 $M$ , 结构化报告 $R$

1  $D \leftarrow \emptyset$

2  $H, P, R \leftarrow \emptyset$

3 循环

4     基于式(4)更新执行计划 $P$

5     基于式(5)更新决策链 $D$

6     基于式(6)获取本轮审查意见

7      $H \leftarrow H \cup \{\text{本轮审查意见}\}$

8 **直到** 通过审查意见且 $D$ 的深度大于等于 $d$

9 顺序执行决策链探针, 数据规整器与浅层机器学习智能体, 获得DAG的度量 $Q$ , 分类器 $M$

10 基于式(7)得到分析报告 $R$

11 返回  $D, M, R$

**结束**

## 2 案例分析

### 2.1 试验设置

#### 2.1.1 数据集

试验验证采用了两个具有代表性的公开轴承故障数据集,分别覆盖了稳态工况和时变工况,以全面评估框架的性能。

#### (1) 清华大学轴承摩擦电故障诊断数据集 D1<sup>[21]</sup>

该数据集采集于稳定工况下的转子试验台,通过一个集成的摩擦电-压电智能鼠笼支架获取振动信号。用于验证本框架在单一领域内的基础诊断能力与决策链生成质量。

数据集共包含5种不同的健康状态:健康、内圈故障、外圈故障、滚动体故障和保持架裂纹。将该数据集的所有5类数据进行划分,其中2个数据集的训练验证与测试集的比例均为1:1。训练验证阶段均做5折交叉验证。

#### (2) 渥太华大学变转速轴承数据集 D2<sup>[22]</sup>

该数据集包含了4种精确设计的时变转速工况,对诊断算法的鲁棒性和适应性提出了更高要求。使用此数据集来评估框架在更复杂的跨工况场景下的零样本泛化性能。

数据集涵盖了3种健康状态(健康、内圈故障、外圈故障)和4种变转速工况(加速、减速、先加速后减速、先减速后加速)。为模拟严苛的工业场景,设计了跨域验证:训练与验证集仅使用工况模式相对简单的“加速”与“减速”数据;而测试集则采用系统在训练中从未见过的、模式更为复杂的“先加速后减速”和“先减速后加速”数据,以评估其泛化能力。

#### 2.1.2 案例配置

为探究不同规模的大语言模型(LLM)作为决策中枢时的表现差异,全面评估框架在不同数据集上的能力,设置了3个独立的验证案例:

##### (1) 案例1

在数据集D1上,采用Gemini 2.0 Flash模型进行验证。此案例旨在评估轻量级模型的基础规划与推理能力。

##### (2) 案例2

在数据集D1上,升级使用能力更强的Gemini 2.5 Pro模型。通过与案例1进行对比,旨在探究更强大的LLM对诊断决策链质量的提升效果。

##### (3) 案例3

在变转速数据集D2上,采用Gemini 2.5 Pro模型进行验证。此案例旨在挑战框架在复杂、非平稳信号条件下的适应性与高级特征工程能力。

3个案例的LLM均采用API调用的方式,这意味着繁重的模型推理在云端完成,本地无需大算力支持。生成的DAG中所包含的所有信号处理算子及下游机器学习模型的计算,可在本地CPU上执行,确保了框架的部署便捷性。

#### 2.1.3 提示词配置

提示词决定了各智能体的具体行为和思考模式,图3和4分别展示了核心智能体规划者和审查者的详细提示词。






图 3 规划者提示词  
Fig. 3 Prompt of planner




图 4 审查者提示词  
Fig. 4 Prompt of reviewer

## 2.2 DAG 迭代过程及其审查反馈

本节将详细展示 3 个案例中多智能体系统动态

生成与演化 DAG 的核心过程。以下重点呈现最终生成的 DAG 结构, “审查者”智能体在每一次“反思迭代”中的决策逻辑见附录 A1 节, 揭示了系统是如何自我优化直至构建出完备的诊断流程。

### 2.2.1 案例一

在此案例中, 系统共进行了 5 次“规划-执行-审查”的迭代, 最终生成了一个深度为 4 的决策链, 如图 5 所示。图中不同线型代表不同迭代轮次, 下方的图例展示了每一个轮次的节点编号对应的具体算子。系统在初次迭代中便展现出良好的对称性规划能力, 为双通道信号并行地部署了包络分析 ( $\Phi_1$ ,  $\Phi_2$ )、FFT ( $\Phi_3$ ,  $\Phi_4$ ) 等核心路径。

在第 2 轮迭代中, 系统没有止步于基础变换, 而是进一步从中间结果中挖掘深层特征, 自主生成了“包络谱-峭度” ( $\Phi_7$ ,  $\Phi_8$ ) 和“FFT 谱-峭度” ( $\Phi_9$ ,  $\Phi_{10}$ ) 这两个在故障诊断中至关重要的特征提取分支。随着迭代的进行, 决策链的深度和宽度被逐步扩展, 最终形成了一个多样化的特征集。

### 2.2.2 案例二

采用能力更强的 Gemini 2.5 Pro 模型后, 系统生成的 DAG 在结构上展现出更高的复杂性和专家级的逻辑性, 如图 6 所示。

系统不仅实现了对双通道信号的对称处理, 还创新性地引入了跨通道的“相关函数” ( $\Phi_{21}$ ) 和时频分析工具 STFT ( $\Phi_{22}$ )。系统自主发现了对包络信号进行频谱分析的黄金准则, 即“希尔伯特包络 ( $\Phi_1$ )  $\rightarrow$  包络谱 FFT ( $\Phi_9$ )  $\rightarrow$  谱峭度/偏度 ( $\Phi_{15}$ ,  $\Phi_{17}$ )”, 精准复现了滚动轴承故障诊断的专家级标准流程, 充分证明了其强大的领域知识理解与推理能力。

### 2.2.3 案例三

面对变转速工况的严峻挑战, 系统生成的 DAG (如图 7 所示) 同样表现出强大的适应性。它同时探索了包络分析 ( $\Phi_1$ ,  $\Phi_2 \rightarrow \Phi_7$ ,  $\Phi_8$ ) 和小波变换 ( $\Phi_3$ ,  $\Phi_4 \rightarrow \Phi_9$ ,  $\Phi_{10}$ ), 这两种都是处理非平稳信号的经典有效手段。

此外, 系统还融合了跨通道相关性分析 ( $\Phi_{13}$ ,  $\Phi_{18}$ ,  $\Phi_{19}$ ), 显示出其在复杂工况下自主构建鲁棒特征集的先进能力, 而非仅仅依赖单一的分析路径。

## 2.3 决策链分类效果

为定量评估自主生成决策链所提取特征的真实有效性, 只在浅层机器学习智能体中配置了支持向量机作为一个浅层的分类模型, 正则化参数选取为 1, SVM 的核函数选取为径向基函数, 其他参数均采用默认设置, 旨在隔离分类器本身带来的性能增益, 从而确保主要诊断结果都主要归功于决策链所生成特征的内在质量。

在三个案例中, 对每个最终 DAG 的叶子节点特




图 5 案例一: DAG 生成过程与算子图例

Fig. 5 Case 1: DAG generation process and operator legend

征(即  $\phi_1, \phi_2, \dots$ )以及由智能体自动选择的 Top-k 特征集成模型进行了分类测试。详细的诊断准确率和 F1 分数见 表 3~5。可以得出如下结论:

(1) LLM 对搭建决策链的规划能力决定了诊断性能的上限

通过对比同一数据集 D1 上的两个案例,发现 LLM 的规模和能力对最终诊断效果具有决定性影响。

如表 3 所示,由轻量级模型 Gemini 2.0 Flash 生成的特征已表现出良好的性能。然而,当升级为更强大的 Gemini 2.5 Pro 后,系统自主构建的决策链所提取的特征,能够取得接近更高的分类性能。这充分证明,一个更强大的 LLM 作为“大脑”,能够规划出更深刻、更有效的诊断路径,从而显著提升最终的诊断精度。

(2) 跨域条件下的强大零样本泛化能力

该决策链仅在简单的“加速”和“减速”工况下进行训练,随后便直接应用于其在训练中从未见过的、模式更复杂的“先加速后减速”复合工况。

结果表明,由系统自主生成的多个特征(如小波相关的  $\phi_3, \phi_9$  和包络谱相关的  $\phi_7$ )依然取得了超过 0.96 的 F1 分数,而最终的集成模型性能更是高达

0.993。这一结果强有力地证明了本框架生成的决策链具备一定的泛化能力与鲁棒性。

2.4 消融试验/失败案例

这项工作的核心挑战是结合上下文工程实现对大语言模型响应的有效控制,因此为了验证本框架各项核心设计的必要性,进行了一系列消融试验。本工作并非追求极致的诊断精确度,而是更关注信号处理工作流的自主构建,以及诊断过程的可解释性、可验证性。本节通过分析几种典型的“失败案例”,反向证明本框架设计的完备性与鲁棒性。

2.4.1 未设定 DAG 深度约束,导致特征提取不足

在此消融试验中,移除了对“审查者”智能体关于最小 DAG 深度的提示约束。系统倾向于生成非常“浅”的决策链,即在经过 1~2 步基础操作后便过早地终止规划。试验日志显示,在无深度约束的测试中,系统在计算了信号的傅里叶变换之后便判定任务完成,其生成的特征在后续分类任务中表现不佳。

机械振动信号特征,尤其是微弱故障特征,往往需要通过一系列算子的级联处理(如滤波-解调-谱分析)才能有效提取。一个过浅的决策链可能仅完成了






图 6 案例二: DAG 生成过程与算子图例

Fig. 6 Case 2: DAG generation process and operator legend




图 7 案例三: DAG 生成过程与算子图例

Fig. 7 Case 3: DAG generation process and operator legend

预处理便终止, 导致核心的故障信息依然被强背景噪声所淹没。因此对 DAG 深度的合理引导是确保智能体进行充分特征探索、避免“浅尝辄止”的关键机制。

#### 2.4.2 缺失算子符号规约, 导致 LLM 规划错误

在此试验中, 向 LLM 提供的算子库信息仅包含算子名称(如傅里叶变换), 而完全移除了神经符号规约。试验表明, LLM 在规划阶段频繁生成无法执

表 3 案例一：由 Gemini 2.0 Flash 生成的诊断指标

Tab. 3 Case 1: diagnostic indices generated by Gemini 2.0 Flash

| 决策链         | 准确率   | F1分数  | 验证准确率             | 验证F1分数            |
|-------------|-------|-------|-------------------|-------------------|
| $\Phi_1$    | 0.901 | 0.899 | $0.739 \pm 0.114$ | $0.723 \pm 0.149$ |
| $\Phi_2$    | 0.810 | 0.809 | $0.698 \pm 0.152$ | $0.681 \pm 0.176$ |
| $\Phi_3$    | 0.872 | 0.857 | $0.991 \pm 0.017$ | $0.991 \pm 0.018$ |
| $\Phi_4$    | 0.951 | 0.950 | $0.945 \pm 0.047$ | $0.945 \pm 0.047$ |
| $\Phi_5$    | 0.732 | 0.721 | $0.731 \pm 0.088$ | $0.719 \pm 0.103$ |
| $\Phi_6$    | 0.493 | 0.491 | $0.422 \pm 0.044$ | $0.417 \pm 0.058$ |
| $\Phi_7$    | 0.433 | 0.423 | $0.397 \pm 0.065$ | $0.389 \pm 0.069$ |
| $\Phi_8$    | 0.370 | 0.371 | $0.403 \pm 0.022$ | $0.404 \pm 0.018$ |
| $\Phi_9$    | 0.358 | 0.358 | $0.348 \pm 0.043$ | $0.344 \pm 0.038$ |
| $\Phi_{10}$ | 0.389 | 0.394 | $0.418 \pm 0.045$ | $0.419 \pm 0.050$ |
| $\Phi_{11}$ | 0.475 | 0.466 | $0.390 \pm 0.096$ | $0.379 \pm 0.096$ |
| $\Phi_{12}$ | 0.355 | 0.356 | $0.364 \pm 0.029$ | $0.363 \pm 0.024$ |
| $\Phi_{13}$ | 0.753 | 0.744 | $0.741 \pm 0.092$ | $0.729 \pm 0.108$ |
| $\Phi_{14}$ | 0.485 | 0.482 | $0.428 \pm 0.044$ | $0.423 \pm 0.062$ |
| $\Phi_{15}$ | 0.525 | 0.525 | $0.554 \pm 0.051$ | $0.536 \pm 0.059$ |
| $\Phi_{16}$ | 0.289 | 0.288 | $0.260 \pm 0.021$ | $0.259 \pm 0.021$ |
| $\Phi_{17}$ | 0.286 | 0.285 | $0.317 \pm 0.018$ | $0.313 \pm 0.020$ |
| $\Phi_{18}$ | 0.436 | 0.436 | $0.444 \pm 0.026$ | $0.443 \pm 0.022$ |
| $\Phi_{19}$ | 0.912 | 0.912 | $0.846 \pm 0.103$ | $0.836 \pm 0.121$ |
| $\Phi_{20}$ | 0.681 | 0.689 | $0.788 \pm 0.051$ | $0.785 \pm 0.058$ |
| $\Phi_{21}$ | 0.488 | 0.465 | $0.464 \pm 0.051$ | $0.447 \pm 0.052$ |
| $\Phi_{22}$ | 0.604 | 0.606 | $0.581 \pm 0.022$ | $0.579 \pm 0.017$ |
| $\Phi_{23}$ | 0.419 | 0.414 | $0.406 \pm 0.031$ | $0.400 \pm 0.029$ |
| $\Phi_{24}$ | 0.383 | 0.388 | $0.407 \pm 0.046$ | $0.408 \pm 0.049$ |
| $\Phi_{25}$ | 0.335 | 0.335 | $0.335 \pm 0.021$ | $0.333 \pm 0.022$ |
| $\Phi_{26}$ | 0.344 | 0.345 | $0.344 \pm 0.047$ | $0.337 \pm 0.045$ |
| $\Phi_{27}$ | 0.518 | 0.507 | $0.439 \pm 0.070$ | $0.432 \pm 0.059$ |
| $\Phi_{28}$ | 0.415 | 0.409 | $0.396 \pm 0.076$ | $0.384 \pm 0.069$ |
| $\Phi_{29}$ | 0.767 | 0.761 | $0.702 \pm 0.079$ | $0.691 \pm 0.095$ |
| $\Phi_{30}$ | 0.505 | 0.505 | $0.416 \pm 0.045$ | $0.412 \pm 0.060$ |
| $\Phi_{31}$ | 0.412 | 0.412 | $0.411 \pm 0.023$ | $0.409 \pm 0.011$ |
| $\Phi_{32}$ | 0.350 | 0.337 | $0.386 \pm 0.044$ | $0.373 \pm 0.054$ |
| $\Phi_{33}$ | 0.488 | 0.465 | $0.464 \pm 0.051$ | $0.447 \pm 0.052$ |
| $\Phi_{34}$ | 0.604 | 0.606 | $0.581 \pm 0.022$ | $0.579 \pm 0.017$ |
| $\Phi_{35}$ | 0.719 | 0.710 | $0.693 \pm 0.085$ | $0.680 \pm 0.097$ |
| $\Phi_{36}$ | 0.488 | 0.485 | $0.410 \pm 0.059$ | $0.404 \pm 0.077$ |
| $\Phi_{37}$ | 0.701 | 0.695 | $0.730 \pm 0.105$ | $0.718 \pm 0.125$ |
| $\Phi_{38}$ | 0.366 | 0.366 | $0.433 \pm 0.017$ | $0.430 \pm 0.024$ |
| 集成          | 0.872 | 0.857 | —                 | —                 |

行或逻辑错误的算子调用指令。

LLM 在进行“工具使用”的符号推理时，完全依赖于其对工具功能的精确理解。若信息不完整，就会导致：

(1)参数“幻觉”

生成不存在的参数，例如为  $\Phi_m$  算子臆造一个汉明窗的参数调用。

(2)逻辑混淆

例如将需要时域信号作为输入的算子错误地应用于一个已经是频域的信号上。神经符号规约的重要性在于，它为 LLM 构建了一份精确且无歧义的

表 4 案例二：由 Gemini 2.5 Pro 生成的诊断指标

Tab. 4 Case 2: diagnostic indices generated by Gemini 2.5 Pro

| 决策链         | 准确率   | F1分数  | 验证准确率             | 验证F1分数            |
|-------------|-------|-------|-------------------|-------------------|
| $\Phi_1$    | 0.901 | 0.899 | $0.739 \pm 0.114$ | $0.723 \pm 0.149$ |
| $\Phi_2$    | 0.810 | 0.809 | $0.698 \pm 0.152$ | $0.681 \pm 0.176$ |
| $\Phi_3$    | 0.872 | 0.857 | $0.991 \pm 0.017$ | $0.991 \pm 0.018$ |
| $\Phi_4$    | 0.951 | 0.950 | $0.945 \pm 0.047$ | $0.945 \pm 0.047$ |
| $\Phi_5$    | 0.360 | 0.356 | $0.362 \pm 0.020$ | $0.363 \pm 0.020$ |
| $\Phi_6$    | 0.383 | 0.393 | $0.371 \pm 0.030$ | $0.370 \pm 0.027$ |
| $\Phi_7$    | 0.286 | 0.285 | $0.317 \pm 0.018$ | $0.313 \pm 0.020$ |
| $\Phi_8$    | 0.436 | 0.436 | $0.444 \pm 0.026$ | $0.443 \pm 0.022$ |
| $\Phi_9$    | 0.977 | 0.977 | $0.997 \pm 0.006$ | $0.997 \pm 0.006$ |
| $\Phi_{10}$ | 0.950 | 0.948 | $0.965 \pm 0.027$ | $0.964 \pm 0.028$ |
| $\Phi_{11}$ | 0.358 | 0.358 | $0.348 \pm 0.043$ | $0.344 \pm 0.038$ |
| $\Phi_{12}$ | 0.389 | 0.394 | $0.418 \pm 0.045$ | $0.419 \pm 0.050$ |
| $\Phi_{13}$ | 0.732 | 0.721 | $0.731 \pm 0.088$ | $0.719 \pm 0.103$ |
| $\Phi_{14}$ | 0.493 | 0.491 | $0.422 \pm 0.044$ | $0.417 \pm 0.058$ |
| $\Phi_{15}$ | 0.511 | 0.508 | $0.488 \pm 0.034$ | $0.483 \pm 0.030$ |
| $\Phi_{16}$ | 0.512 | 0.514 | $0.519 \pm 0.028$ | $0.519 \pm 0.026$ |
| $\Phi_{17}$ | 0.519 | 0.513 | $0.470 \pm 0.046$ | $0.466 \pm 0.042$ |
| $\Phi_{18}$ | 0.505 | 0.506 | $0.540 \pm 0.017$ | $0.539 \pm 0.015$ |
| $\Phi_{19}$ | 0.475 | 0.466 | $0.390 \pm 0.096$ | $0.379 \pm 0.096$ |
| $\Phi_{20}$ | 0.355 | 0.356 | $0.364 \pm 0.029$ | $0.363 \pm 0.024$ |
| $\Phi_{21}$ | 0.974 | 0.974 | $0.950 \pm 0.022$ | $0.949 \pm 0.023$ |
| $\Phi_{22}$ | 0.799 | 0.733 | $0.996 \pm 0.006$ | $0.996 \pm 0.006$ |
| 集成          | 0.978 | 0.978 | —                 | —                 |

表 5 案例三：由 Gemini 2.5 Pro 生成的诊断指标

Tab. 5 Case 3: diagnostic indices generated by Gemini 2.5 Pro

| 决策链         | 准确率   | F1分数  | 验证准确率             | 验证F1分数            |
|-------------|-------|-------|-------------------|-------------------|
| $\Phi_1$    | 0.707 | 0.709 | $0.759 \pm 0.051$ | $0.755 \pm 0.055$ |
| $\Phi_2$    | 0.340 | 0.338 | $0.321 \pm 0.007$ | $0.320 \pm 0.007$ |
| $\Phi_3$    | 0.991 | 0.991 | $0.988 \pm 0.009$ | $0.988 \pm 0.009$ |
| $\Phi_4$    | 0.342 | 0.339 | $0.309 \pm 0.007$ | $0.305 \pm 0.008$ |
| $\Phi_5$    | 0.392 | 0.392 | $0.407 \pm 0.008$ | $0.407 \pm 0.008$ |
| $\Phi_6$    | 0.340 | 0.339 | $0.336 \pm 0.007$ | $0.336 \pm 0.007$ |
| $\Phi_7$    | 0.966 | 0.967 | $0.978 \pm 0.013$ | $0.978 \pm 0.013$ |
| $\Phi_8$    | 0.341 | 0.340 | $0.317 \pm 0.005$ | $0.316 \pm 0.006$ |
| $\Phi_9$    | 0.994 | 0.994 | $0.997 \pm 0.002$ | $0.997 \pm 0.002$ |
| $\Phi_{10}$ | 0.372 | 0.372 | $0.372 \pm 0.025$ | $0.370 \pm 0.024$ |
| $\Phi_{11}$ | 0.392 | 0.392 | $0.407 \pm 0.008$ | $0.407 \pm 0.008$ |
| $\Phi_{12}$ | 0.333 | 0.168 | $0.331 \pm 0.004$ | $0.167 \pm 0.002$ |
| $\Phi_{13}$ | 0.360 | 0.360 | $0.370 \pm 0.004$ | $0.369 \pm 0.004$ |
| $\Phi_{14}$ | 0.655 | 0.657 | $0.679 \pm 0.009$ | $0.678 \pm 0.011$ |
| $\Phi_{15}$ | 0.587 | 0.591 | $0.529 \pm 0.060$ | $0.536 \pm 0.056$ |
| $\Phi_{16}$ | 0.330 | 0.330 | $0.327 \pm 0.011$ | $0.327 \pm 0.011$ |
| $\Phi_{17}$ | 0.331 | 0.331 | $0.334 \pm 0.004$ | $0.333 \pm 0.004$ |
| $\Phi_{18}$ | 0.332 | 0.332 | $0.335 \pm 0.004$ | $0.335 \pm 0.004$ |
| $\Phi_{19}$ | 0.341 | 0.341 | $0.334 \pm 0.004$ | $0.334 \pm 0.004$ |
| $\Phi_{20}$ | 0.353 | 0.352 | $0.336 \pm 0.021$ | $0.335 \pm 0.022$ |
| $\Phi_{21}$ | 0.357 | 0.357 | $0.376 \pm 0.004$ | $0.375 \pm 0.004$ |
| 集成          | 0.993 | 0.993 | —                 | —                 |

“操作手册”, 从根本上保证了规划的准确性和执行的安全性, 杜绝了因“幻觉”导致的失败。

### 3 结 论

本文提出了一种面向工业自主信号处理的神经符号多智能体框架, 旨在解决传统专家系统固化与深度学习模型“黑箱”之间的核心矛盾。本框架以大型语言模型(LLM)为认知核心, 通过创新的多智能体协作机制, 将 LLM 强大的符号推理能力与经过严格规约的信号处理算子库相结合, 成功实现了对机械振动信号处理决策链的自主规划、执行与优化。引入了“规划-执行-审查”的架构以提升决策的全局性与鲁棒性, 并通过动态演化的有向无环图(DAG)实现了诊断流程的自适应构建。试验充分证实, 本框架能够自主构建出相当于人类专家设计的信号分析方案, 在保持决策链可解释的前提下, 于单域及跨域诊断任务中均展现出有效性与较强的泛化能力。具体贡献可归纳如下:

(1) 本文将 LLM 智能体与一个经过神经符号规约的信号处理算子库进行深度融合, 构建了连接高级语义任务与底层数值计算的桥梁。

(2) 本文设计了一个由“规划者”“执行者”和“审查者”构成的多智能体协作框架, 实现对信号处理决策链的迭代优化。

(3) 提出以动态演化的 DAG 来表征整个信号处理决策链, 其中每个节点/每条边都对应一个具有明确物理含义的算子/数据流。

本框架的可解释性贯穿信号处理决策链的构建、执行和输出全过程:

#### (1) 架构层面

DAG 中的每个节点和边均映射到具有明确物理语义的信号处理算子及其数据流, 形成了一条完整可追溯的诊断推理链路, 使得从原始信号到最终诊断结论的每一步变换都有据可查。

#### (2) 输出层面

报告智能体能够自动生成结构化的诊断报告, 不仅包含最终诊断结论, 还完整记录了关键中间变换结果与特征演化过程, 为工程技术人员提供了可理解、可验证的决策依据。

#### (3) 实证层面

系统成功复现了领域专家的经典诊断路径, 如“希尔伯特包络→FFT→谱峭度/偏度”这一经典的轴承故障诊断路径, 充分验证了其决策逻辑的专业性与可信度。更重要的是, 本框架生成的决策链具有知识迁移能力。一次成功规划所得的 DAG 结构及其算子组合模式, 可作为领域知识被存储和重用, 为

新场景、新任务提供初始化的先验知识, 从而加速后续诊断任务的收敛, 实现了从单次学习到知识积累的智能进化。

立足于本工作, 未来可探索和开辟的多个前沿方向包括:

#### (1) 拓展至多模态信息融合

现实中的工业诊断常需综合振动、声学、温度等多源信息。未来, 可将本框架拓展至多模态数据, 设计更复杂的跨模态融合算子, 使智能体能够进行更全面地异构信息决策。

#### (2) 实现在线增量学习

当前框架主要在批量数据上生成决策链。引入在线增量学习机制, 使智能体能够根据新接收的数据流持续微调和优化诊断流程, 将是实现设备全生命周期自适应诊断的关键一步。

#### (3) 探索跨领域知识迁移

本研究验证了框架在不同轴承间的泛化能力。未来更具挑战性的任务是, 如何让智能体在面对从旋转机械到土木结构监测等完全不同的领域时, 能高效地注入新知识并迁移已有经验。

#### (4) 构建人机协同回路

为进一步提升系统的鲁棒性与实用性, 可探索融合“人在回路”的机制。在智能体遇到不确定或高风险决策时, 可主动请求人类专家指导, 从而将 AI 的效率与人类的深层经验智慧相结合。

#### (5) 完善理论基础保障

本工作在实践上验证了一种新范式的有效性。未来, 从理论上对其决策过程的收敛性、最优性等进行形式化分析与证明, 将是探索神经符号智能体系统性能边界、推动其走向成熟的重要研究方向。

### 参考文献:

- [1] 何清波, 李天奇, 彭志科. 旋转机械故障诊断中的振动信号模型综述 [J]. 振动、测试与诊断, 2024, 44(4): 629-639.  
HE Qingbo, LI Tianqi, PENG Zhike. Vibration signal models in rotating machinery fault diagnosis: a review[J]. Journal of Vibration, Measurement & Diagnosis, 2024, 44(4): 629-639.
- [2] 甄冬, 田少宁, 郭俊超, 等. 改进型 EEMD 和 MSB 解调方法及其在轴承故障特征提取中的应用 [J]. 振动工程学报, 2023, 36(5): 1447-1456.  
ZHEN Dong, TIAN Shaoning, GUO Junchao, et al. An improved decomposition method using EEMD and MSB and its application in rolling bearing fault feature extraction[J]. Journal of Vibration Engineering, 2023, 36(5): 1447-1456.
- [3] WANG D, PENG Z K, XI L F. The sum of weighted normalized square envelope: a unified framework for kurtosis, negative entropy, Gini index and smoothness index for machine health monitoring[J]. Mechanical Systems and Signal



- Processing, 2020, 140: 106725.
- [4] 王冬, 侯炳昌, 王玉婷, 等. 稀疏测度和复杂性测度及其在设备健康监测中的研究进展[J]. 机械工程学报, 2025, 61(1): 123-139.  
WANG Dong, HOU Bingchang, WANG Yuting, et al. Advances in sparsity measures and complexity measures for machine health monitoring[J]. Journal of Mechanical Engineering, 2025, 61(1): 123-139.
- [5] YAN R Q, SHANG Z G, XU H, et al. Wavelet transform for rotary machine fault diagnosis: 10 years revisited[J]. Mechanical Systems and Signal Processing, 2023, 200: 110545.
- [6] CHEN Y Y, ZHANG D, YAN R Q, et al. Applications of domain generalization to machine fault diagnosis: a survey[J]. IEEE/CAA Journal of Automatica Sinica, 2025, 12(10): 1963-1984.
- [7] 严如强, 商佐港, 王志颖, 等. 可解释人工智能在工业智能诊断中的挑战和机遇: 先验赋能[J]. 机械工程学报, 2024, 60(12): 1-20.  
YAN Ruqiang, SHANG Zuogang, WANG Zhiying, et al. Challenges and opportunities of XAI in industrial intelligent diagnosis: priori-empowered[J]. Journal of Mechanical Engineering, 2024, 60(12): 1-20.
- [8] 林京, 焦金阳. 可解释机械智能诊断技术的研究进展与挑战[J]. 机械工程学报, 2023, 59(20): 215-224.  
LIN Jing, JIAO Jinyang. Research progress and challenges of interpretable mechanical intelligent diagnosis[J]. Journal of Mechanical Engineering, 2023, 59(20): 215-224.
- [9] LI Q, LI H, HU W Y, et al. Transparent operator network: a fully interpretable network incorporating learnable wavelet operator for intelligent fault diagnosis[J]. IEEE Transactions on Industrial Informatics, 2024, 20(6): 8628-8638.
- [10] LI Q, LIU Y K, SUN S L, et al. Deep expert network: a unified method toward knowledge-informed fault diagnosis via fully interpretable neuro-symbolic AI[J]. Journal of Manufacturing Systems, 2024, 77: 652-661.
- [11] LI Q, QIN L C, XU H F, et al. Transparent information fusion network: an explainable network for multi-source bearing fault diagnosis via self-organized neural-symbolic nodes[J]. Advanced Engineering Informatics, 2025, 65: 103156.
- [12] LIAO X M, CHEN C, WANG Z W, et al. Large language model assisted fine-grained knowledge graph construction for robotic fault diagnosis[J]. Advanced Engineering Informatics, 2025, 65: 103134.
- [13] SHI F C, CHEN L, ZHOU M S, et al. A stepwise intelligence generative method for structured maintenance guidance documents based on knowledge graph augmented LLM[J]. Advanced Engineering Informatics, 2025, 67: 103523.
- [14] LIN L, ZHANG S H, FU S, et al. FD-LLM: large language model for fault diagnosis of complex equipment[J]. Advanced Engineering Informatics, 2025, 65: 103208.
- [15] BRITO L C, SUSTO G A, BRITO J N, et al. Fault diagnosis using explainable AI: a transfer learning-based approach for rotating machinery exploiting augmented synthetic data[J]. Expert Systems with Applications, 2023, 232: 120860.
- [16] ALUR R, DURRETT G, KRESS-GAZIT H, et al. Report on NSF workshop on science of safe AI[EB/OL]. (2025-06-24)[2025-10-05]. <https://arxiv.org/abs/2506.22492>.
- [17] SHEN Y L, SONG K T, TAN X, et al. HuggingGPT: solving AI tasks with ChatGPT and its friends in hugging face[EB/OL]. (2023-11-03)[2025-10-05]. <https://arxiv.org/abs/2303.17580>.
- [18] HUANG Y C, YANG L F. Winning gold at IMO 2025 with a model-agnostic verification-and-refinement pipeline[EB/OL]. (2025-07-25)[2025-10-05]. <http://arxiv.org/abs/2507.15855>.
- [19] WANG L, MA C, FENG X Y, et al. A survey on large language model based autonomous agents[J]. Frontiers of Computer Science, 2024, 18(6): 186345.
- [20] 陈超, 沈飞, 严如强. 改进 LSSVM 迁移学习方法的轴承故障诊断[J]. 仪器仪表学报, 2017, 38(1): 33-40.  
CHEN Chao, SHEN Fei, YAN Ruqiang. Enhanced least squares support vector machine-based transfer learning strategy for bearing fault diagnosis[J]. Chinese Journal of Scientific Instrument, 2017, 38(1): 33-40.
- [21] QIN L C, ZHANG L F, FENG J G, et al. A hybrid triboelectric-piezoelectric smart squirrel cage with self-sensing and self-powering capabilities[J]. Nano Energy, 2024, 124: 109506.
- [22] HUANG H, BADDOUR N. Bearing vibration data collected under time-varying rotational speed conditions[J]. Data in Brief, 2018, 21: 1745-1749.

第一作者: 李 奇(1997—), 男, 博士研究生。

E-mail: liq22@tsinghua.org.cn

通信作者: 秦朝烨(1980—), 男, 博士, 副教授。

E-mail: qinzy@tsinghua.edu.cn

## 附录 A

### A1 三个案例的反思内容

#### A1.1 案例一中审查者的反思迭代过程

##### (1) 反思迭代 1

当前 DAG 深度: 2。智能体决策: 需要重新规划(推断)。决策理由: 当前 DAG 深度为 2, 低于最低要求 4。尽管已执行的步骤有效, 但工作流过浅, 需要扩展以提取更多故障诊断相关特征。应当引入更高级的信号处理技术, 例如, 可对已计算的 RMS 值本身进行进一步的统计分析, 或对原始信号(ch1, ch2)应用小波分解进行时频分析。此外, 在 FFT 计算后, 应执行如谱熵、谱峭度或主频识别等特征提取。

##### (2) 反思迭代 2

当前 DAG 深度: 3。智能体决策: 需要重新规划(推断)。决策理由: DAG 结构有效, 但深度和特征多样性有限。尽管时域特征(RMS、熵)和频域特征(谱峭度)很有用, 但整体工作流过浅, 无法捕捉轴承故障的复杂性。双通道的对称性处理很好, 但需要从 FFT 和希尔伯特变换结果中提取更多特征, 例如从 FFT 输出中提取统计特征(均值、标准差等)、计算不同频带能量或探索谱质心等。同时, 应引入小波变换以分解信号。

##### (3) 反思迭代 3

当前 DAG 深度: 3。智能体决策: 需要重新规划

(推断)。决策理由: 工作流已提取了时域、频域及希尔伯特包络特征, 但尚未达到最低深度 4。建议添加小波变换或短时傅里叶变换(STFT)等更多时频分析技术, 以捕捉轴承信号的非平稳特性, 这些方法能揭示在 FFT 中不明显的瞬态故障。

#### (4) 反思迭代 4

当前 DAG 深度: 3。智能体决策: 需要重新规划(推断)。决策理由: 工作流起点良好, 包含了双通道的时域和频域特征。建议添加小波变换以捕捉瞬态事件和时频域特征。更进一步的探索可涉及非线性动力学特征(如李雅普诺夫指数), 但这取决于信号特性和计算资源。同时, 在特征提取后可能需要进行特征选择或降维(如 PCA)。

#### (5) 反思迭代 5

当前 DAG 深度: 4。智能体决策: 完成。决策理由: 工作流进展顺利, 在时域和频域上均具有合理的特征多样性。下一步的建议: 可以考虑添加基于小波变换的特征来增强故障诊断能力, 或者将重点转移到融合现有特征并构建分类模型上。

### A1.2 案例二中审查者的反思迭代过程

#### (1) 反思迭代 1

当前 DAG 深度: 2。智能体决策: 需要重新规划。决策理由: 当前的 DAG(有向无环图)提供了一个坚实的基础, 整合了关键的时域统计特征(如峰度 kurtosis、波峰因子 crest\_factor)和必要的变换(如快速傅里叶变换 FFT、希尔伯特包络 Hilbert envelope), 并具有良好的通道对称性。然而, 当前流程的深度仅为 2, 未达到最低要求 4。从架构上看, 该流程尚未利用中间信号的变换结果。为了实现有效的轴承故障诊断, 下一个合理的步骤是对包络信号进行频谱分析。因此, 强烈建议对 Hilbert\_envelope 节点应用 FFT 变换(例如, FFT(Hilbert\_envelope\_01\_ch1))。这将生成包络谱, 这是一个识别特征故障频率、显著推进目标达成的关键工具。

#### (2) 反思迭代 2

当前 DAG 深度: 4。智能体决策: 需要重新规划。决策理由: 该流程在架构上非常出色, 整合了故障诊断的关键技术, 如时域统计、FFT 和包络分析。对双通道的对称处理以及引入跨通道相干性是最佳实践。然而, 为了最大化发现故障特征, 还有一个关键领域尚未探索。强烈建议现在引入基于小波的分析。对输入信号(ch1, ch2)应用连续小波变换(CWT)将提供一个互补的时频表示方法, 这种方法对于检测早期轴承故障特有的非平稳瞬态信号非常有效。

#### (3) 反思迭代 3

当前 DAG 深度: 4。智能体决策: 完成。决策理

由: 该流程展示了一种复杂且全面的轴承故障诊断架构方法。它正确地对双通道实现了并行、对称的处理, 整合了关键技术, 如时域统计、直接频谱分析(FFT→谱峭度 Spectral Kurtosis), 以及最重要的、用于识别轴承故障的包络分析(希尔伯特变换 Hilbert→FFT→统计量 Stats)。跨通道相干性(coherence)和短时傅里叶变换(STFT)的加入进一步丰富了特征集。该流程逻辑合理、多样性高, 并已满足最小深度要求。对于初始的分类模型而言, 当前的特征集是全面的。

### A1.3 案例三中审查者的反思迭代过程

#### (1) 反思迭代 1

当前 DAG 深度: 2。智能体决策: 需要重新规划(need\_replan)。决策理由: 当前的 DAG 是有效的, 并且通过探索时域统计、包络分析和小波变换, 展现了良好的算子多样性。然而, 当前深度为 2 未满足最低深度为 4 的要求。更重要的是, 工作流已经生成了强大的中间信号表示(如 Hilbert\_envelope, wavelet\_transform), 但尚未从中提取特征。为了更好地实现变转速故障诊断的目标, 下一步应专注于处理这些中间信号。例如, 对包络信号应用 FFT 以识别轴承故障频率, 或从“小波系数矩阵”中计算统计特征(如能量或熵)。

#### (2) 反思迭代 2

当前 DAG 深度: 3。智能体决策: 需要重新规划(need\_replan)。决策理由: 该流程是健康的, 但当前深度为 3, 尚未达到最低深度为 4 的要求。目前的 DAG 架构非常出色, 特别是通过 Hilbert\_envelope→FFT 生成了包络谱。为了进一步增强该工作流, 建议直接从这些新生成的包络谱(例如, FFT\_01\_Hilbert\_envelope\_01\_ch1 和 FFT\_02\_Hilbert\_envelope\_02\_ch2)中提取特征, 以量化轴承故障特有的周期性冲击。

#### (3) 反思迭代 3

当前 DAG 深度: 4。智能体决策: 完成(finish)。决策理由: 该工作流在架构上是健全的, 有效运用了对轴承故障诊断至关重要的包络谱分析和小波变换。其在时域、频域和时/频域的特征多样性非常出色, 且处理链逻辑合理。DAG 已满足最小深度要求, 可被视为完整。为了未来增强, 若要明确处理“变转速”工况, 可考虑引入阶次分析。这将涉及通过轴转速对包络谱进行归一化, 以提取特定阶次(如 BPFO、BPFI)的故障特征, 使其对速度变化不敏感。

## A2 输出的分析报告

本框架的最终输出是由报告智能体生成的、结构化的综合分析报告。该报告不仅呈现最终的诊断结论, 更旨在实现整个决策过程的全程可追溯与可

解释性。以最具挑战性的案例三(变转速工况)为例,如图 A1 所示。

轴承变转速工况故障诊断分析报告

本报告旨在分析所提供的轴承振动信号,以识别潜在的健康状况和故障模式。根据用户指令,本次分析的数据集包含变转速工况下的信号,这意味着故障特征会随转速变化而改变。参考集与测试集均包含三种状态:健康(Health)、内圈故障 (Inner Race Fault) 和外圈故障 (Outer Race Fault)。核心目标是通过对测试信号与参考集进行对比,实现对每个测试信号的精确分类。

1. 流程概览

本次诊断任务的处理流程从两个独立的输入通道 (ch1 和 ch2) 采集原始振动信号开始。为了从复杂的变转速信号中提取有效的故障特征,我们设计并执行了一个多层次的信号处理与特征提取流程 (DAG):

- 信号预处理:
  - 对两个通道的原始信号 (ch1, ch2) 分别应用了 **希尔伯特包络 (Hilbert Envelope)** 和 **连续小波变换 (Continuous Wavelet Transform)**。希尔伯特包络主要用于解调幅度调制信息,而小波变换则非常适合分析变转速这类非平稳信号的时频特性。
- 特征提取:
  - 时域与频域统计特征:** 直接从原始信号 ch1 和 ch2 中提取了多种统计指标,例如峰度 (Kurtosis)、峭度因子 (Crest Factor)、均方根 (RMS)、波形因子 (Shape Factor) 等。
  - 包络谱特征:** 对希尔伯特包络信号进行 **快速傅里叶变换 (FFT)**, 得到包络谱。并从包络谱中提取了均值 (Mean)、标准差 (Std)、峰度 (Kurtosis) 和偏度 (Skew) 等特征。
  - 小波特征:** 对小波变换后的时频矩阵,我们计算了其在不同尺度 (Scale) 上的能量均值 (Mean) 和标准差 (Std)。
  - 多通道谱特征:** 计算了两个通道间的 **相干性 (Coherence)**, 并提取了其均值和最大值,以评估通道间的线性相关性。
- 分类与诊断:
  - 所有提取出的特征被用于训练和评估一个机器学习分类模型。最终,通过一个 **集成模型 (Ensemble Model)** 结合所有特征的优势,对测试信号的健康状态进行最终分类。

(a) 报告第1部分  
(a) Section 1 of the report

2. 特征洞察

本次分析未提供特征间的相似度统计数据 (similarity\_stats 为空), 因此无法对特征的区分度进行直接的量化比较。然而,我们可以通过各特征在机器学习模型中的独立表现来间接评估其有效性。

- 表现最优的特征:
  - mean\_03\_wavelet\_transform\_03\_ch1 (F1-score: 0.994): 基于 **ch1 小波变换的均值特征** 取得了近乎完美的分类效果。这表明小波变换成功地捕捉到了与转速变化无关的、稳定的故障模式能量分布,是本次诊断任务中最具区分度的特征。
  - wavelet\_transform\_03\_ch1 (F1-score: 0.991): 完整的小波变换时频图本身也包含极高的信息量,分类准确率极高。
  - fft\_01\_hilbert\_envelope\_01\_ch1 (F1-score: 0.967): 基于 **ch1 包络谱的分析** 也表现出色。这是经典的轴承故障诊断方法,通过解调发现故障引起的周期性冲击,在变转速工况下依然有效。
- 表现最差的特征:
  - spectral\_flatness\_06\_ch2 (F1-score: 0.168): **ch2 的谱平坦度** 几乎没有提供任何有用的分类信息。
  - 绝大多数来自 ch2 的特征 (如 rms\_06\_ch2, hilbert\_envelope\_02\_ch2 等) 以及部分单值统计量 (如 crest\_factor\_07\_ch1) 的 F1 分数均在 0.33 左右,这与三类问题中的随机猜测水平相当。
- 原因推测:
  - 通道 ch1 是关键信息源。** 无论是小波分析还是包络谱分析, ch1 提供的信号质量远高于 ch2。这可能与传感器的安装位置有关, ch1 的位置更接近故障源,能够更清晰地捕捉到故障冲击。
  - ch2 可能存在噪声干扰或信息冗余。** ch2 信号的特征区分度普遍较低,表明该通道可能受到严重噪声污染,或者其测量位置无法有效反映轴承的健康状态。
  - 高级信号处理方法的优越性。** 在变转速工况下,小波变换和包络谱分析等能够处理非平稳信号的方法,显著优于传统的时域统计指标 (如RMS、Kurtosis), 后者因无法解耦转速变化和故障冲击而失效。

(b) 报告第2部分  
(b) Section 2 of the report

3. 模型评估

为了对轴承的健康状态进行准确分类,我们评估了基于不同特征的机器学习模型性能,并构建了一个集成模型以综合所有特征的诊断能力。详细性能指标如下表所示,其中交叉验证 (CV) 结果反映了模型在不同数据子集上的泛化能力。

| 特征/模型                                      | Accuracy | F1 Score | CV Accuracy | CV F1 Score |
|--------------------------------------------|----------|----------|-------------|-------------|
| hilbert_envelope_01_ch1                    | 0.706539 | 0.709033 | 0.758891    | 0.754649    |
| hilbert_envelope_02_ch2                    | 0.339629 | 0.338302 | 0.320853    | 0.319765    |
| wavelet_transform_03_ch1                   | 0.991385 | 0.991385 | 0.988072    | 0.988065    |
| wavelet_transform_04_ch2                   | 0.341507 | 0.338874 | 0.308924    | 0.304770    |
| kurtosis_05_ch1                            | 0.392092 | 0.391570 | 0.407334    | 0.407307    |
| rms_06_ch2                                 | 0.339518 | 0.339495 | 0.335984    | 0.335905    |
| fft_01_hilbert_envelope_01_ch1             | 0.966424 | 0.966527 | 0.978131    | 0.978082    |
| fft_02_hilbert_envelope_02_ch2             | 0.341295 | 0.339787 | 0.316877    | 0.316231    |
| mean_03_wavelet_transform_03_ch1           | 0.994036 | 0.994035 | 0.997460    | 0.997459    |
| std_04_wavelet_transform_04_ch2            | 0.372322 | 0.371580 | 0.371880    | 0.369775    |
| spectral_kurtosis_05_ch1                   | 0.392092 | 0.391570 | 0.407334    | 0.407307    |
| spectral_flatness_06_ch2                   | 0.333444 | 0.167892 | 0.330572    | 0.166595    |
| coherence_07_ch1_ch2                       | 0.360062 | 0.359801 | 0.369781    | 0.369117    |
| mean_01_fft_01_hilbert_envelope_01_ch1     | 0.654738 | 0.657363 | 0.678706    | 0.678195    |
| kurtosis_02_fft_01_hilbert_envelope_01_ch1 | 0.586812 | 0.590621 | 0.529379    | 0.535723    |
| std_03_fft_02_hilbert_envelope_02_ch2      | 0.325689 | 0.329697 | 0.326927    | 0.326068    |
| skew_04_fft_02_hilbert_envelope_02_ch2     | 0.330683 | 0.330621 | 0.333554    | 0.333495    |
| mean_05_coherence_07_ch1_ch2               | 0.332339 | 0.332322 | 0.334769    | 0.334596    |
| max_06_coherence_07_ch1_ch2                | 0.340623 | 0.340616 | 0.333965    | 0.333521    |
| crest_factor_07_ch1                        | 0.352883 | 0.351947 | 0.336315    | 0.334518    |
| shape_factor_08_ch2                        | 0.357301 | 0.357108 | 0.375856    | 0.374888    |
| ensemble                                   | 0.993042 | 0.993037 | /           | /           |

评估摘要:

- 集成模型表现卓越:** 最终的 **集成模型 (Ensemble)** 取得了 **99.3%** 的准确率和F1分数。这一结果证明,通过整合多个维度的特征 (尤其是 **ch1 的小波和包络谱特征**), 模型能够非常可靠地对轴承在变转速工况下的三种状态 (健康、内圈故障、外圈故障) 进行区分。
- 单特征性能差异巨大:** 如前所述,不同特征的诊断能力相差悬殊。这突显了在复杂工况下选择正确信号处理方法和特征的重要性。

(c) 报告第3部分  
(c) Section 3 of the report

4. 结论与建议

诊断结论:

- 本次分析所采用的诊断流程 **非常成功**。集成模型达到了 **99.3%** 的分类准确率,表明该方法能够有效、可靠地识别变转速工况下的轴承健康状态及内、外圈故障。
- 诊断模型的成功主要归功于对 **ch1 信号的深度处理**, 特别是 **小波变换** 和 **包络谱分析** 两种技术,它们是应对变转速挑战的关键。

维护建议:

- 部署诊断模型:** 鉴于集成模型的高精度和高可靠性,建议将此分析流程和模型部署到实际的设备健康监测系统中,用于在线、自动化的故障预警和诊断。
- 审查 ch2 传感器:** 通过 **ch2** 及其衍生特征在本轮分析中几乎未提供有效信息。建议对 **ch2** 对应的传感器进行检查,包括其 **物理安装位置、连接线路和自身健康状况**, 以确认其是否工作正常或安装位置是否合理。若确认无效,可在未来监测中考虑将其移除,以降低数据采集和计算成本。
- 优化特征集:** 为提高计算效率,未来可考虑精简特征集,仅保留 **wavelet\_transform\_03\_ch1, fft\_01\_hilbert\_envelope\_01\_ch1** 等少数几个表现最优的特征进行建模。这可以在基本不损失精度的情况下,大幅减少计算负担。

(d) 报告第4部分  
(d) Section 4 of the report

5. Code 代码部分

在数据处理流程 (DAG) 中,小波变换 (wavelet\_transform) 等计算密集型算子是潜在的性能瓶颈。以下代码片段展示了如何通过并行化处理来优化该算子,以提高大规模数据集分析的效率。这里我们使用 **joblib** 库对多个信号的连续小波变换 (CWT) 进行并行计算。

```
1 import numpy as np
2 import pywt
3 from joblib import Parallel, delayed
4
5 def compute_cwt(signal, scales, wavelet_name):
6     """
7     计算单个信号的连续小波变换。
8     Args:
9         signal (np.ndarray): 一维输入信号。
10        scales (np.ndarray): 小波变换的尺度数组。
11        wavelet_name (str): 小波函数名称, e.g., 'morf'。
12    Returns:
13        np.ndarray: CWT 系数矩阵。
14    """
15
16    # 确保信号是一维的
17    if signal.ndim > 1:
18        signal = signal.flatten()
19
20    coefficients, _ = pywt.cwt(signal, scales, wavelet_name)
21    return coefficients
22
23
24 def optimized_wavelet_transform_on_batch(signals_batch, scales, wavelet_name='morf', n_jobs=-1):
25     """
26     使用并行计算优化对一批信号的小波变换处理。
27
28     Args:
29         signals_batch (list of np.ndarray or np.ndarray): 包含多个信号的列表或二维数组。
30         scales (np.ndarray): 小波变换的尺度数组。
31         wavelet_name (str): 小波函数名称。
32         n_jobs (int): 并行处理使用的CPU核心数。-1表示使用所有可用核心。
33
34     Returns:
35         list of np.ndarray: 每个信号对应的CWT系数矩阵列表。
36     """
37
38    # 使用joblib的Parallel和delayed函数实现并行化
39    # delayed(compute_cwt) 创建一个函数的“延迟”版本
40    # Parallel(...) 会在多个CPU核心上并行执行这些延迟的函数调用
41    cwt_results = Parallel(n_jobs=n_jobs)(
42        delayed(compute_cwt)(signal, scales, wavelet_name) for signal in signals_batch
43    )
44
45    return cwt_results
46
47
48 # -- 示例 --
49 # 假设我们有一批信号数据 (例如: 100个信号, 每个信号长度为4096)
50 # signals_to_process = np.random.rand(100, 4096)
51 # scales_to_use = np.arange(1, 129)
52
53 # # 调用优化后的函数
54 # # cwt_matrices = optimized_wavelet_transform_on_batch(signals_to_process, scales_to_use)
55
56 # print("通过并行化, 小波变换算子的计算效率得到显著提升, 特别是在处理大量信号时。")
```

优化说明: 上述代码通过 **joblib.Parallel** 将原本需要串行循环处理的多个信号的小波变换任务, 分配到多个CPU核心上并行执行。这种方式可以成倍缩短处理时间, 尤其适用于包含大量测试样本的诊断场景, 是提升整个DAG执行效率的有效手段。

(e) 报告第5部分  
(e) Section 5 of the report

图 A1 案例三的分析报告  
Fig. A1 Analysis report for case 3